
Support Vector Machines y Clasificación Supervisada

Daniel Lugaresi Palomares


Diciembre, 2025

1. Planteamiento del problema


Supongamos que disponemos de un conjunto de datos que se dividen en una serie de clases prefijadas, y que nuestro objetivo es clasificar una nueva observación dentro de una de las clases anteriores. Por ejemplo, podemos tener un conjunto de pacientes con un determinado diagnóstico y un grupo de control sano, junto a mediciones de ciertos marcadores de interés en los individuos de cada grupo. Nos preguntamos si, con los datos que tenemos, podremos clasificar a futuros pacientes en uno de estos dos grupos, dados los valores de sus marcadores. Este tipo de problemas se pueden abordar a través de la *clasificación supervisada*, y ya conocemos alguna de las técnicas que se emplean, como los SVMs (máquinas de vectores de soporte). En particular, hemos estudiado los SVMs en el caso en que los datos son linealmente separables, donde tomábamos el hiperplano separador de máximo margen para separar las observaciones; siendo nuestra regla de clasificación ver en qué semiespacio se encontraba la nueva observación.

Sin embargo, ¿qué ocurre si nuestros datos no son linealmente separables? Por ejemplo, puede suceder que la forma de cualquier separador razonable sea claramente no lineal, como muestra la Figura 1a. También puede ocurrir que los datos sean *casi* linealmente separables, pero que haya una pequeña “mezcla” entre datos de diferentes clases, como podemos ver en la Figura 1b. En este trabajo, veremos cómo se pueden resolver este tipo de problemas, planteando primero de forma teórica algunas de las técnicas desarrolladas para abordarlos, comentando cómo el dual puede ayudar a resolver o interpretar el problema; y

después utilizando  para resolver un problema real de este tipo a través de los métodos descritos, interpretando convenientemente los resultados apoyándonos en la dualidad.



(a) Datos claramente no separables mediante un separador lineal.



(b) Datos casi linealmente separables.

Figura 1: Ejemplos de clasificación supervisada con SVMs en los que no se puede utilizar un separador lineal para diferenciar perfectamente los grupos.

1.1. Caso linealmente separable — SVMs

En esta sección vamos a resumir brevemente, a modo de recordatorio, cómo se plantea el problema de optimización en el caso linealmente separable, ya que es en esta formulación en la que se van a basar los problemas que presentaremos en el resto del trabajo.

Consideremos un conjunto de l observaciones, $\{\mathbf{x}^1, \dots, \mathbf{x}^l\} \subset \mathbb{R}^n$. Además, para cada observación $i \in \{1, \dots, l\}$, tenemos n características $x_1^i, \dots, x_n^i$, y su clasificación en uno de dos grupos: $y_i \in \{-1, +1\}$.

El hiperplano separador de máximo margen es el hiperplano $H(\mathbf{w}, -b)$ que maximiza la distancia de la observación más cercana al mismo. Trabajando con el hiperplano normalizado por $\beta = \min_{i \in \{1, \dots, l\}} |\mathbf{w}^T \mathbf{x}^i + b|$, la menor distancia posible es 1, o sea, $y_i(\mathbf{w}^T \mathbf{x}^i + b) \geq 1$. Estas condiciones las añadimos como restricciones al problema primal para asegurar que clasifiquemos correctamente las observaciones de entrenamiento. Ahora bien, a través del cálculo de la proyección sobre el hiperplano de una de las observaciones, $\mathbf{x}^k$, que minimizan la distancia a este, obtenemos el margen que deja el hiperplano con respecto a los datos de entrenamiento:

$$\text{dist}(\mathbf{x}^k, H(\mathbf{w}, -b)) = 1/\|\mathbf{w}\|,$$

que será entonces la función objetivo a maximizar. Equivalentemente, tenemos que mini-

mizar $\|\mathbf{w}\|^2$, y el problema primal se formula como

$$\begin{aligned} (P) \quad & \text{Minimizar}_{\mathbf{w}, b} \quad \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ & \text{Sujeto a} \quad y_i(\mathbf{w}^T \mathbf{x}^i + b) - 1 \geq 0, \quad i = 1, \dots, l. \end{aligned} \quad (1)$$

El problema de optimización obtenido es convexo y se puede calcular su dual a través de la función lagrangiana $\mathcal{L}^D(\boldsymbol{\alpha})$ y las condiciones de optimalidad $\nabla \mathcal{L}^D(\boldsymbol{\alpha}) = 0$, resultando

$$\begin{aligned} (D) \quad & \text{Maximizar}_{\boldsymbol{\alpha}} \quad \sum_{i=1}^l \alpha_i - \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l \alpha_i \alpha_j y_i y_j (\mathbf{x}^i)^T \mathbf{x}^j \\ & \text{Sujeto a} \quad \sum_{i=1}^l \alpha_i y_i = 0, \\ & \quad \alpha_i \geq 0, \quad i = 1, \dots, l. \end{aligned} \quad (2)$$

Para terminar, cabe recordar que la motivación para maximizar el margen es que se puede acotar el error que comete un clasificador lineal al clasificar datos nuevos por este margen, $1/\|\mathbf{w}\|$.

2. Caso casi linealmente separable – C-SVMs

Vamos a suponer ahora que nuestros datos son *casi* linealmente separables, es decir, que estamos en una situación como la de la Figura 1b, en la que hay unos pocos datos de un grupo que están “mezclados” con los del otro. Las referencias principales para esta sección son [5] y [3].

2.1. Planteamiento del problema primal

Para abordar el problema casi lineal se desarrollan los denominados C-SVMs, cuyo supuesto principal es que todavía podemos encontrar un hiperplano suficientemente bueno que nos permita clasificar correctamente observaciones nuevas, colocando las problemáticas a una distancia óptima del hiperplano escogido de forma que los errores cometidos a la hora de clasificar sean mínimos, aunque no podamos colocarlas todas con el margen que queremos (y unas pocas queden, posiblemente, mal clasificadas).

Siguiendo la idea del párrafo anterior, introduciremos unas variables de holgura $\xi_i, i = 1, \dots, l$ asociadas a cada restricción del problema (1), de manera que relajamos la “distan-

cia” al hiperplano normalizado, permitiendo que haya observaciones con $|\mathbf{w}^T \mathbf{x}^i + b| < 1^\dagger$:

$$y_i(\mathbf{w}^T \mathbf{x}^i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

Pensemos en qué significan estas nuevas variables: puede ocurrir que

- $\xi_i = 0$: en este caso, $y_i(\mathbf{w}^T \mathbf{x}^i + b) \geq 1$, y la observación de entrenamiento en cuestión está fuera del margen o cae sobre él, con que está lo suficientemente “lejos” del hiperplano.
- $0 < \xi_i \leq 1$: entonces $1 > y_i(\mathbf{w}^T \mathbf{x}^i + b) \geq 0$, y la observación cae dentro del margen (está más “cerca” de lo que nos gustaría del hiperplano).
- $\xi_i > 1$: entonces $y_i(\mathbf{w}^T \mathbf{x}^i + b) \leq 0$, y la observación no se clasifica correctamente.

De nuevo, podemos permitirnos una observación que no se clasifique correctamente siempre que el hiperplano sea lo suficientemente bueno como para clasificar bien la mayoría de puntos.

Notemos que, dado que una observación está mal clasificada si $\xi_i > 1$, entonces una cota superior para el número de puntos mal clasificados es $\sum_{i=1}^l \xi_i$. Añadiendo este término a la función objetivo del problema de minimización (1), nos aseguramos de obtener el menor número posible de observaciones mal clasificadas, y además tratamos de encontrar los ξ_i lo más pequeños posible, que es lo que nos interesa. Además, dependiendo del problema a resolver, nos puede interesar controlar el equilibrio entre clasificar correctamente la mayor cantidad posible de puntos y maximizar el margen. Por eso, se añade un término de regularización C que multiplica a $\sum_{i=1}^l \xi_i$ (de ahí el nombre de C-SVMs). Valores más altos de C penalizan mucho los errores, pero encuentran márgenes más pequeños, mientras que un valores más bajos de C encuentran márgenes más grandes a cambio de penalizar poco los errores (veremos posteriormente cómo el dual nos permite visualizar esto de forma rigurosa). Así, el problema de optimización a resolver para encontrar el hiperplano de “margen flexible” es

$$\begin{aligned} (P_S) \quad & \text{Minimizar} \quad \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^l \xi_i \\ & \text{Sujeto a} \quad y_i(\mathbf{w}^T \mathbf{x}^i + b) + \xi_i - 1 \geq 0, \quad i = 1, \dots, l, \\ & \quad \quad \quad \xi_i \geq 0, \quad i = 1, \dots, l. \end{aligned} \tag{3}$$

Notemos que este nuevo problema satisface las siguientes propiedades:

1. La función objetivo es convexa: en efecto, la función $\mathbf{w}^T I_{n \times n} \mathbf{w}$ es convexa, pues su hessiana es la identidad, que es definida positiva. Además, la función $C \sum_{i=1}^l \xi_i$ es

[†]El caso linealmente separable suele denominarse de “margen duro”, ya que las observaciones de entrenamiento satisfacen, dado el hiperplano separador de máximo margen, $y_i(\mathbf{w}^T \mathbf{x}^i + b) \geq 1$. Por el contrario, el caso casi linealmente separable decimos que es de “margen flexible”, por las holguras que introducimos en las restricciones.

lineal, así que es convexa; y la suma de funciones convexas es convexa.

2. Las restricciones son lineales: la restricción $y_i(\mathbf{w}^T \mathbf{x}^i + b) + \xi_i - 1 \geq 0$ es lineal en $\mathbf{w}, b$ y ξ_i .

Por tanto, como primera aproximación al problema, observamos que se trata de un problema de optimización convexo, al igual que en el caso de margen duro.

2.2. Cálculo del problema dual

Dado que, como hemos probado en la subsección anterior, estamos ante un problema convexo, podremos aplicar el Teorema de Dualidad Fuerte y encontrar una equivalencia entre la resolución del primal y del dual. En este caso, podremos utilizar la dualidad para ayudarnos a interpretar mejor el significado de todos los elementos del problema, igual que en el caso del margen duro.

Para llevar a cabo el cálculo de la función lagrangiana necesitamos asociar multiplicadores de Lagrange a los dos conjuntos de restricciones que tenemos. Así, los α_i serán los asociados a las restricciones de margen, y los μ_i los asociados a las restricciones de no negatividad de las holguras ξ_i . Entonces,

$$L((\mathbf{w}, b, \xi), \boldsymbol{\alpha}, \boldsymbol{\mu}) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^l \xi_i - \sum_{i=1}^l \alpha_i (y_i(\mathbf{w}^T \mathbf{x}^i + b) - 1 + \xi_i) - \sum_{i=1}^l \mu_i \xi_i.$$

Podemos reescribirla para que el cálculo de la función dual sea ligeramente más cómodo de la siguiente manera:

$$L((\mathbf{w}, b, \xi), \boldsymbol{\alpha}, \boldsymbol{\mu}) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^l \alpha_i y_i \mathbf{w}^T \mathbf{x}^i - b \sum_{i=1}^l \alpha_i y_i + \sum_{i=1}^l \alpha_i + \sum_{i=1}^l \xi_i (C - \alpha_i - \mu_i). \quad (4)$$

Para calcular el dual del problema (3), recordemos que este se definía como

$$\text{Maximizar}_{\boldsymbol{\alpha} \geq 0, \boldsymbol{\mu} \geq 0} \mathcal{L}^D(\boldsymbol{\alpha}, \boldsymbol{\mu}),$$

donde la función lagrangiana viene dada por $\mathcal{L}^D(\boldsymbol{\alpha}, \boldsymbol{\mu}) = \inf_{\mathbf{w}, b, \xi} L((\mathbf{w}, b, \xi), \boldsymbol{\alpha}, \boldsymbol{\mu})$. No tenemos ahora que, dada la forma de la función lagrangiana L (Ecuación (4)), fijados $\boldsymbol{\alpha}$ y $\boldsymbol{\mu}$, el problema $\mathcal{L}^D(\boldsymbol{\alpha}, \boldsymbol{\mu})$ es convexo en las variables $\mathbf{w}, b, \xi$. Así, podemos utilizar la condición de optimalidad $\nabla_{\mathbf{w}, b, \xi} L((\mathbf{w}, b, \xi), \boldsymbol{\alpha}, \boldsymbol{\mu}) = 0$. Calculamos todas las parciales y las igualamos a cero:

1. Minimizamos respecto a b :

$$\frac{\partial L}{\partial b} = 0 \iff \sum_{i=1}^l \alpha_i y_i = 0.$$

2. Minimizamos respecto a $\mathbf{w}$: para cada $j \in \{1, \dots, n\}$,

$$\frac{\partial L}{\partial w_j} = w_j - \sum_{i=1}^l \alpha_i y_i x_j^i = 0 \implies \mathbf{w} = \sum_{i=1}^l \alpha_i y_i \mathbf{x}^i.$$

3. Minimizamos respecto a ξ : para cada $j \in \{1, \dots, l\}$,

$$\frac{\partial L}{\partial \xi_j} = C - \alpha_i - \mu_i = 0 \implies C = \alpha_i + \mu_i.$$

En cuanto a la última condición, podemos expresar $\mu_i = C - \alpha_i, i = 1, \dots, l$ e imponer como restricción $\alpha_i \in [0, C]$. Para terminar de calcular el problema dual, reescribimos la función lagrangiana $\mathcal{L}^D(\boldsymbol{\alpha}, \boldsymbol{\mu})$ con lo obtenido anteriormente, llegando a

$$\mathcal{L}^D(\boldsymbol{\alpha}, \boldsymbol{\mu}) = \sum_{i=1}^l \alpha_i - \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l \alpha_i \alpha_j y_i y_j (\mathbf{x}^i)^T \mathbf{x}^j.$$

De esta manera, el problema dual del C-SVM es

$$\begin{aligned} (D_S) \quad & \text{Maximizar} \quad \sum_{i=1}^l \alpha_i - \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l \alpha_i \alpha_j y_i y_j (\mathbf{x}^i)^T \mathbf{x}^j \\ & \text{Sujeto a} \quad \sum_{i=1}^l \alpha_i y_i = 0, \\ & \quad 0 \leq \alpha_i \leq C, \quad i = 1, \dots, l. \end{aligned}$$

Notemos que los multiplicadores μ_i de las holguras ξ_i no aparecen en el problema dual, pues se pueden determinar como $\mu_i = C - \alpha_i$, dada una solución $\boldsymbol{\alpha}$ de dicho problema.

2.3. Interpretaciones

Gracias a la formulación del problema dual podemos extraer las siguientes conclusiones: dado un óptimo $(\boldsymbol{\alpha}, \boldsymbol{\mu})$ del dual,

1. Puesto que $\mathbf{w} = \sum_{i=1}^l \alpha_i y_i \mathbf{x}^i$, el vector normal al hiperplano que encontramos es una combinación lineal de los puntos de entrenamiento, solo aquellos puntos con $\alpha_i > 0$ contribuyen a su cálculo.
2. También hemos visto que $\sum_{i=1}^l \alpha_i y_i = 0$, de manera que hay un equilibrio entre las contribuciones de ambas clases al cálculo del hiperplano.
3. El Teorema de Dualidad Fuerte, con la condición de holguras complementarias ase-

gura que

$$\begin{aligned}\alpha_i(y_i(\mathbf{w}^T \mathbf{x}^i + b) - 1 + \xi_i) &= 0, \\ \mu_i \xi_i &= 0 \iff (C - \alpha_i)\xi_i = 0.\end{aligned}$$

Esto implica que, dada la i -ésima observación de entrenamiento,

- a) Si $\alpha_i = 0$, entonces $\xi_i = 0$, y según la interpretación que teníamos de estas holguras y la primera de las conclusiones que acabamos de obtener, la observación en cuestión cae fuera del margen y además no influye en la elección del hiperplano. Está bien clasificada.
- b) Si $0 < \alpha_i < C$, entonces $\xi_i = 0$ y además la observación se encuentra sobre el margen, pues $y_i(\mathbf{w}^T \mathbf{x}^i + b) = 1$. Estas observaciones permiten calcular el término b ,

$$b = y_i - \mathbf{w}^T \mathbf{x}^i,$$

que necesitamos conocer para obtener la función de clasificación.

- c) Si $\alpha_i = C$, entonces $\xi_i \geq 0$, de manera que podemos estar ante un punto justo en el margen, mal clasificado o dentro del margen. Son los puntos que tiran con más fuerza del hiperplano, contribuyendo a $\mathbf{w}$ con peso C .

Notemos que, en caso de que tengamos una observación con holgura $\xi_i > 0$ (mal clasificados o dentro del margen), entonces, según el análisis que acabamos de hacer, $\alpha_i = C$. Unido a la conclusión 3a), se observa claramente el rol del valor C que comentamos al inicio y la importancia de escogerlo adecuadamente: cuanto más hagamos crecer C , más penalizamos los errores, y entonces habrá más puntos con $0 \leq \alpha_i < C$ bien clasificados. Sin embargo, aumentar C también hace que los valores de α_i puedan ser más grandes, haciendo crecer entonces la norma del vector normal al hiperplano y disminuyendo el margen $1/\|\mathbf{w}\|$. Por el contrario, disminuir C provoca que el mayor valor de α_i sea pequeño, con que aumentamos el margen $1/\|\mathbf{w}\|$, a cambio de que muchas observaciones alcancen el valor más grande $\alpha_i = C$, y sean posiblemente puntos mal clasificados o fuera del margen.

3. Caso no linealmente separable – Kernel SVMs

Para esta sección, vamos a suponer que nuestros datos no son linealmente separables, como ocurría en el ejemplo de la Figura 1a. En este caso, podemos calcular el hiperplano separador en una dimensión mayor a través de una transformación $\phi : \mathbb{R}^n \rightarrow \mathcal{H}$. $\mathcal{H}$ es el espacio de características, que se denota así porque suele ser un espacio de Hilbert, aunque nosotros trabajaremos con $\mathcal{H} \subseteq \mathbb{R}^m$ por simplicidad. Las referencias consultadas para esta sección son [1] y [4].

Por ejemplo, consideremos los datos de la Figura 1a y la transformación $\phi : \mathbb{R}^2 \rightarrow \mathbb{R}^6$

dada por

$$\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2, x_1^2, x_2^2).$$

Si pasamos los datos a este espacio y aplicamos un SVM lineal, obtenemos un vector $\mathbf{w} = (a, b, c, d, e, f)$ tal que

$$\{\mathbf{x} \in \mathbb{R}^6 : a + bx_1 + cx_2 + dx_1x_2 + ex_1^2 + fx_2^2 = \mathbf{w}^T \phi(\mathbf{x}) = 0\},$$

que sería nuestro hiperplano separador, y en este caso se trata de una cónica en $\mathbb{R}^2$. Para los datos que consideramos en la Figura 1a, aplicar el SVM en dimensión 6 debería dar una cónica similar a la de ecuación $x_1^2 + x_2^2 = 0$.

3.1. El truco de las funciones kernel

Recordemos ahora el dual del problema linealmente separable (Ecuación (2)). Si queremos pasar nuestros datos a un espacio de dimensión mayor, aplicando la transformación ϕ , el cálculo de la función objetivo requiere calcular los productos escalares $\phi(\mathbf{x}^i)^T \phi(\mathbf{x}^j)$, para $i, j \in \{1, \dots, l\}$, lo cual puede llegar a ser muy costoso computacionalmente. Es por ello que se plantea el uso de un *kernel*, que es una función $K : \mathbb{R}^n \rightarrow \mathbb{R}$ que calcula directamente el producto escalar $\phi(\mathbf{x}^i)^T \phi(\mathbf{x}^j)$. Por ejemplo, si volvemos al caso de la cónica que tratamos antes, escogiendo la función de transformación $\phi(\mathbf{x}) = (1, \sqrt{2}x_1, \sqrt{2}x_2, \sqrt{2}x_1x_2, x_1^2, x_2^2)$, tenemos que calcular para plantear el dual:

$$\begin{aligned} K(\mathbf{x}^i, \mathbf{x}^j) &= \phi(\mathbf{x}^i)^T \phi(\mathbf{x}^j) = 1 + 2x_1^i x_1^j + 2x_2^i x_2^j + 2x_1^i x_2^j x_1^j x_2^j + (x_1^i)^2 (x_1^j)^2 + (x_2^i)^2 (x_2^j)^2 \\ &= (1 + (\mathbf{x}^i)^T \mathbf{x}^j)^2. \end{aligned}$$

Este producto escalar deriva el kernel llamado *kernel polinómico de grado 2*, que es el que induce curvas de separación dadas por cónicas en el espacio de partida.

En general, para que el problema resultante (que definiremos a continuación), siga siendo un problema convexo, a los kernel se les pide que satisfagan las *condiciones de Mercer*, que son las siguientes:

1. K simétrico: $K(\mathbf{x}^i, \mathbf{x}^j) = K(\mathbf{x}^j, \mathbf{x}^i)$, para todo $i, j = 1, \dots, l$.
2. K definido positivo: la matriz $(K(\mathbf{x}^i, \mathbf{x}^j))_{i,j \in \{1, \dots, l\}}$ debe ser definida positiva.

En general, se puede demostrar [4], que si tenemos un kernel K que satisface las condiciones de Mercer, entonces podemos construir una transformación ϕ que llega a un espacio de Hilbert $\mathcal{H}$ donde K actúa como el producto escalar. Cabe destacar que esta función ϕ no siempre se puede conocer explícitamente y que $\mathcal{H}$ puede ser infinito.

Algunos ejemplos de kernel son, por ejemplo, el kernel polinómico de grado d , dado por

$$K(\mathbf{x}^i, \mathbf{x}^j) = (c + (\mathbf{x}^i)^T \mathbf{x}^j)^d,$$

con c una constante (desplazamiento); o el kernel gaussiano de funciones de base radial (RBF), dado por

$$K(\mathbf{x}^i, \mathbf{x}^j) = \exp(-\gamma \|\mathbf{x}^i - \mathbf{x}^j\|_2^2),$$

con γ una constante. Este último, representa un ejemplo interesante de kernel que da lugar a un espacio de características de Hilbert $\mathcal{H}$ de dimensión infinita [2].

3.2. Formulación del problema de optimización

Estamos ahora en condiciones de enunciar el problema dual asociado al kernel-SVM. Dado un kernel $K(\mathbf{x}^i, \mathbf{x}^j)$ satisfaciendo las condiciones de Mercer, el problema dual suavizado (convexo) es

$$\begin{aligned} (D_K) \quad & \text{Maximizar} \quad \sum_{i=1}^l \alpha_i - \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l \alpha_i \alpha_j y_i y_j K(\mathbf{x}^i, \mathbf{x}^j) \\ & \text{Sujeto a} \quad \sum_{i=1}^l \alpha_i y_i = 0, \\ & \quad 0 \leq \alpha_i \leq C, \quad i = 1, \dots, l. \end{aligned}$$

En este caso, trabajar con el dual nos permite trabajar solo con el kernel $K(\mathbf{x}^i, \mathbf{x}^j)$, ofreciendo así una ventaja clara frente al primal, donde requerimos trabajar explícitamente con el espacio de características $\mathcal{H}$, que puede ser incluso infinito. Además, el dual nos permite trabajar con kernels K para los que ni siquiera podríamos calcular la transformación al espacio de características ϕ . El primal vendría dado por

$$\begin{aligned} (P_K) \quad & \text{Minimizar}_{\mathbf{w} \in \mathcal{H}, b, \xi} \quad \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^l \xi_i \\ & \text{Sujeto a} \quad y_i (\mathbf{w}^T \phi(\mathbf{x}^i) + b) + \xi_i - 1 \geq 0, \quad i = 1, \dots, l, \\ & \quad \xi_i \geq 0, \quad i = 1, \dots, l, \end{aligned}$$

donde se pueden apreciar los comentarios que acabamos de realizar. Notemos que con el producto escalar usual de $\mathbb{R}^n$, $K(\mathbf{x}^i, \mathbf{x}^j) = (\mathbf{x}^i)^T \mathbf{x}^j$, recuperamos el problema suavizado, Ecuaciones (2) y (1).

3.3. Construcción de la frontera de separación a partir de la solución del dual

Para terminar con las secciones teóricas, vamos a explicar cómo podemos obtener la curva que separa los grupos en $\mathbb{R}^n$ a partir del hiperplano separador calculado por el kernel elegido.

Sea α un óptimo del problema dual (D_K) , el vector normal al hiperplano viene dado por

$$\mathbf{w} = \sum_{i=1}^l \alpha_i y_i \phi(\mathbf{x}^i),$$

y entonces $\mathbf{w}$ actúa sobre ϕ como sigue:

$$\mathbf{w}^T \phi(\mathbf{x}) = \sum_{i=1}^l \alpha_i y_i \phi(\mathbf{x})^T \phi(\mathbf{x}) = \sum_{i=1}^l \alpha_i y_i K(\mathbf{x}^i, \mathbf{x}). \quad (5)$$

Así pues, la frontera que separa los datos viene dada, en $\mathbb{R}^n$, por la curva de nivel

$$f(\mathbf{x}) = \sum_{i=1}^l \alpha_i y_i K(\mathbf{x}^i, \mathbf{x}) + b = 0.$$

Para el cálculo del b óptimo, basta recordar que, como comentamos al estudiar el problema suavizado, si para algún $j = 1, \dots, l$, $0 < \alpha_j < C$, entonces $y_j(\mathbf{w}^T \phi(\mathbf{x}^j) + b) = 1$, de manera que, según la Ecuación (5),

$$1 = y_j \left(\sum_{i=1}^l \alpha_i y_i K(\mathbf{x}^i, \mathbf{x}^j) + b \right).$$

Como $y_i = 1$ ó $y_i = -1$, tendremos que

$$b = y_i - \sum_{j=1}^l \alpha_j y_j K(\mathbf{x}^j, \mathbf{x}^i).$$

Podría darse el caso en que todas las restricciones saturan $\alpha_i = C$, en cuyo caso estamos cayendo en sobreajuste y nos indica que debemos aumentar el valor de C .

4. Aplicación a un conjunto de datos reales

El objetivo de esta sección será modelar tanto el C-SVM como el Kernel-SVM en , y encontrar un conjunto de datos reales al que poder aplicarle las técnicas vistas, para después interpretar los resultados haciendo uso de la solución de los problemas duales.

A continuación, introducimos la base de datos elegida y el problema que vamos a estudiar.

En el Instituto Nacional de Estadística (INE) se realiza anualmente la Encuesta de Condiciones de Vida (ECV)[§], con el objetivo de conocer el porcentaje de población en

[§]https://www.ine.es/dyngs/INEbase/categoria.htm?c=Estadistica_P&cid=1254735976608, fecha de consulta: 03-12-25.

riesgo de exclusión social y las causas del mismo. En particular, una parte de esta encuesta está dedicada a los hogares, donde se recogen variables relativas a la renta y a las condiciones de vida y se determina si el hogar está en riesgo de pobreza o no.

Para este trabajo, hemos tomado los datos de la ECV de 2024[†] y las siguientes variables (todas las variables se encuentran detalladas en el fichero de diseño del registro que se descarga junto a los datos):

- **vhPobreza** Variable binaria que indica si el hogar en cuestión está o no en riesgo de pobreza.
- **HY020** Variable numérica que indica la renta disponible total del hogar (antes de transferencias sociales).
- **HH070** Variable numérica que indica los gastos de la vivienda: alquiler + intereses de la hipoteca + otros gastos.

Entonces, nos preguntamos si, en caso de tener una nueva vivienda $\mathbf{x}^0$, podemos clasificarla como “hogar en riesgo de pobreza” u “hogar sin riesgo de pobreza”, simplemente a partir de los datos de renta disponible total del hogar y de los gastos de la vivienda.

Para ello, dado que tenemos una gran cantidad de datos, generaremos un subconjunto de ellos, quedándonos aleatoriamente con veinte de ambos grupos, y después entrenaremos un modelo de SVM resolviendo los problemas duales con . Así, en  hemos obtenido un subconjunto de los datos con las variables de interés (escaladas, la renta dividida entre un factor de 10000 y los gastos entre 100), representado en la Figura 2a. Podemos observar que parecen tener un carácter casi linealmente separable, con algunas observaciones de ambos grupos mezcladas.


Para resolver el problema de optimización con SVMs asociado, no vamos a entrar en la elección de C , escogeremos un valor de $C = 1$, que no penalice en exceso los errores ni permita mucha libertad al margen, de manera que tengamos un equilibrio. Tampoco entraremos en cómo se escogen los diversos parámetros de los kernel, tomando para el kernel polinómico $d = 2$ (kernel cuadrático) y $c = 1$, y para el kernel gaussiano $\gamma = 1$.[‡]

Así, formulando y resolviendo en , obtenemos los resultados recogidos en la Tabla 1.

Como podemos observar, el Kernel Gaussiano utiliza una gran cantidad de puntos para calcular la el hiperplano de separación. Esto puede deberse a que es un kernel muy flexible, que intenta agotar toda la información posible para encontrar fronteras con forma muy compleja. Es un kernel “universal” [2], que nos da una función de clasificación “buena” a cambio de perder interpretabilidad de las variables duales. Por otro lado, el kernel

[†]<https://www.ine.es/prodyser/microdatos.htm>, fecha de consulta: 03-12-25.

[‡]Se suelen escoger estos parámetros, C incluido, por validación cruzada, es decir, probando varios valores para una parte de los datos, y viendo cuál clasifica mejor la parte restante.



(a) Renta total del hogar frente a gastos de la vivienda. En rojo, las observaciones de hogares que no son de riesgo, en azul las que sí lo son.

(b) Hiperplano de separación calculado por el método lineal suavizado, $C = 1$.

Figura 2: Datos seleccionados de la ECV de 2024 realizada por el INE.

Método	w	Índices i con $0 < \alpha_i \leq C$	b	Función de clasificación
Gaussiano	No se puede calcular	1, 2, 4, 5, 7, 8, 9, 10, 11, 14, 15, 16, 17, 19, 20, 21, 23, 25, 26, 28, 29, 31, 32, 33, 34, 35, 36, 37, 38, 39, 40	-0.3030	$f(x) = \sum_i \alpha_i y_i e^{-\ x - x_i\ _2^2} + b$
Polinómico	Difícil de calcular	1, 8, 9, 14, 16, 20, 25, 29, 31, 32, 36, 38, 40	1.5015	$f(x) = \sum_i \alpha_i y_i (1 + x^\top x_i)^2 + b$
Suavizado	$\begin{pmatrix} -1.57 \\ 0.14 \end{pmatrix}$	1, 9, 14, 15, 16, 19, 20, 22, 29, 31, 32, 33, 36, 38, 40	2.7541	$f(x) = w^\top x + b$

Tabla 1: Comparación de los tres métodos SVM aplicados a los datos de la ECV de 2024. En azul las observaciones para las que $0 < \alpha_i < C$, con $C = 1$.

polinómico y el lineal suavizado utilizan menos información para el cálculo del hiperplano separador.

Recordemos que aquellas restricciones con $0 < \alpha_i \leq C$ son las que influyen en el cálculo del hiperplano separador. Además, para aquellas que no llegan a saturar la restricción, es decir, $0 < \alpha_i < C$, se tiene $\xi_i = 0$, y por holguras complementarias $y_i(\mathbf{w}^T \mathbf{x}^i + b) = 1$, encontrándose en el margen óptimo y fijando su posición. Así pues, para encontrar los hogares que más influyen a la hora de calcular la función de separación, podemos quedarnos con la unión de aquellos que cumplan $0 < \alpha_i < C$, entre el polinómico y el suavizado. Podríamos pensar también en tomar la intersección de las observaciones con $0 < \alpha_i \leq C$ para los tres métodos, pero entonces tendríamos que todas las observaciones consideradas saturan $\alpha_i = C$ (salvo la 38). Entonces, estaríamos teniendo en cuenta, posiblemente, muchas observaciones mal clasificadas o fuera del margen, que representan más bien datos complicados de tratar que datos cruciales para calcular el hiperplano. Cabe destacar que las interpretaciones se deben hacer para cada valor de C considerado por separado, pues aumentarlo o disminuirlo puede cambiar completamente los valores de α_i .

Siguiendo la idea del párrafo anterior, los hogares que más influyen a la hora de calcular el hiperplano separador para $C = 1$ son los siguientes: 8, 15, 16, 25, 31, 33, 38, habiendo tres hogares en riesgo de pobreza y tres sin riesgo de pobreza. Por otro lado, la única observación que se encuentra en la intersección de las observaciones con $0 < \alpha_i < C$ para los tres métodos es el hogar 38. Concluimos así que, con $C = 1$, el 38 es el hogar más importante a la hora de fijar la posición del margen, y se trata de un hogar que no está en riesgo de pobreza, con una renta disponible de 35793.86 euros y un gasto de vivienda de 1358.69 euros.

Por último, podemos comentar que para el método suavizado, hay muchas observaciones que alcanzan $\alpha_i = C$, lo que nos hace pensar que hemos elegido C pequeño, y hemos dado importancia a maximizar el margen, a cambio de tener más observaciones mal clasificadas. Podemos calcular el margen como $1/\|\mathbf{w}\| = 0.6344$. Sin embargo, para el polinómico no hay tantas observaciones con $\alpha_i = C$, solo ocho, de manera que con los parámetros $d = 2$ y $c = 1$ tenemos bien clasificadas la gran mayoría de observaciones a cambio de un margen más pequeño. En conclusión, $C = 1$ es, en nuestro contexto, un valor más “grande” para el kernel polinómico que para el lineal suavizado.

Referencias

- [1] Bayle, P., & Schapire, R. (2018). *COS 511: Theoretical Machine Learning, Lecture 14*. Apuntes de clase, Princeton University, NJ.
- [2] Christmann, A., & Steinwart, I. (2010). Universal kernels on non-standard input spaces. *Advances in Neural Information Processing Systems*, 23:406–414.

- [3] Scarlett, J. (2021). *Convex Optimization Notes (Lecture 06a)*. Apuntes de clase, Curso CS5339, National University of Singapore, Singapur. Disponible en: https://www.comp.nus.edu.sg/~scarlett/CS5339_notes/06a-Convex_Notes.pdf.
- [4] Schölkopf, B., & Smola, A. J. (2002). *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*. Cambridge, MA: MIT Press.
- [5] Torres Borrás, A. (2019). *Support Vector Machines*. Apuntes del curso de aprendizaje automático para el INE. Instituto de Ciencias Matemáticas (ICMAT), Madrid. Disponible en: <https://albertotb.com/curso-ml-R/Rmd/07-svm/07-svm.html>.